KRZYSZTOF SOKÓŁ-SZOŁTYSEK
PROGRAM 4
GRUPA PONIEDZIAŁKOWA

WYNIKI

A. N = 192

C. Dla mojego N i próby 600 macierzy otrzymałem wyniki :
mean t: 192.060681577
standard deviation t: 1.4544023297

Jak zauważyłem przeciętna wartość widma bardzo nieznacznie odbiega od zadanego dowolnego N(niska standardowa dewiacja).

D.

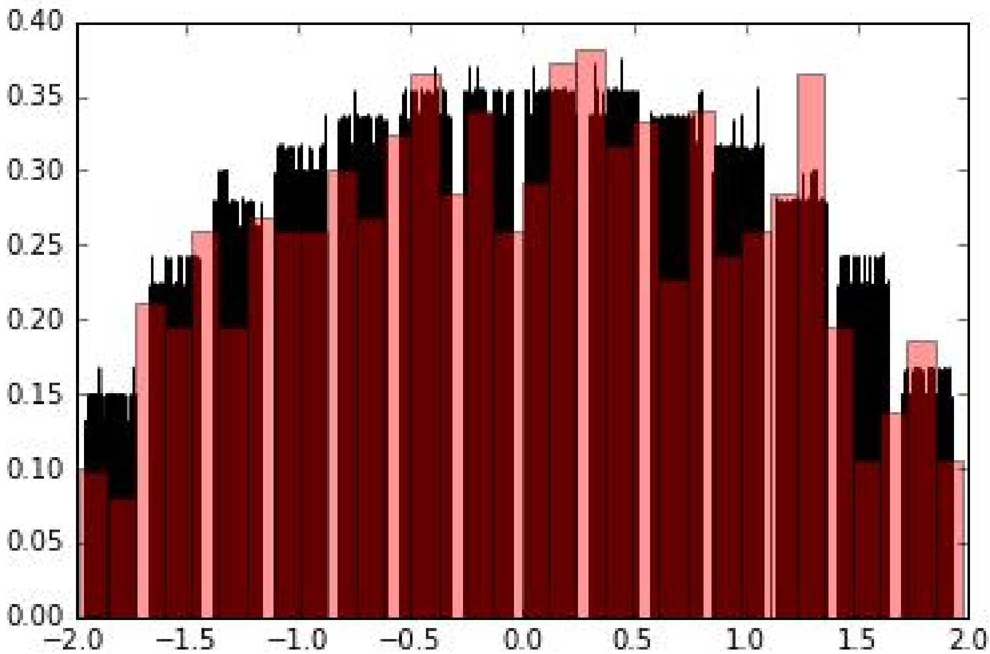

Dla 600 macierzy * 192 wartości własne = 115200 wartości własnych (bins = sqrt, czarny kolor) uzyskałem po unormowaniu wykres który przypomina rozklad półkolisty Wignera(100 losowych próbek z rozkładu, kolor czerwony, R = 2) - rozkład wartości własnych dużych losowych macierzy jest ograniczony właśnie w ten sposób (Winger semicircle law).

E.

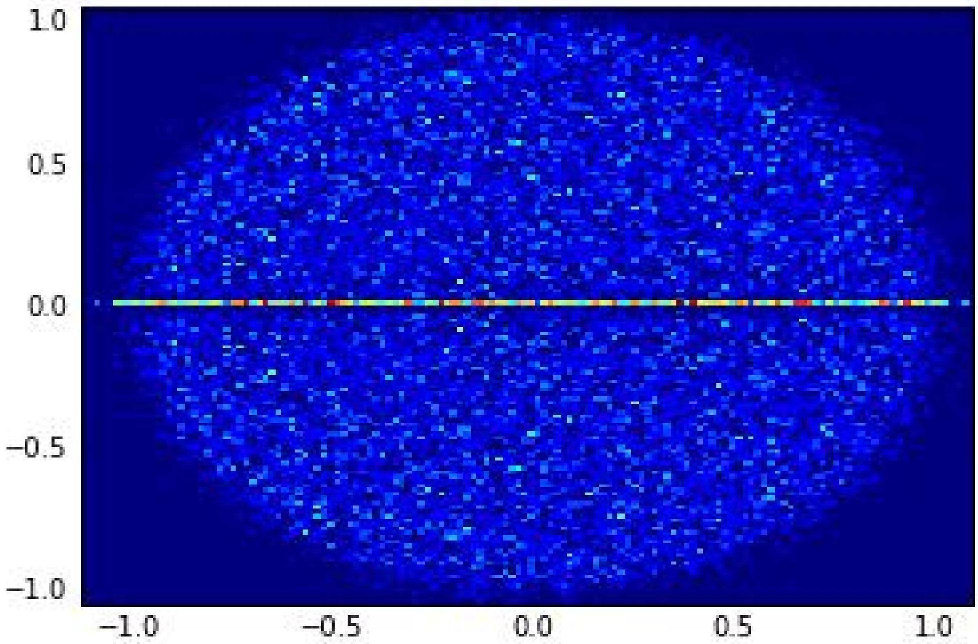

Wartości własne losowej macierzy ułożyły się w koło, większe zagęszczenie na osi rzeczywistej - zgodnie z Circular Law.

F.

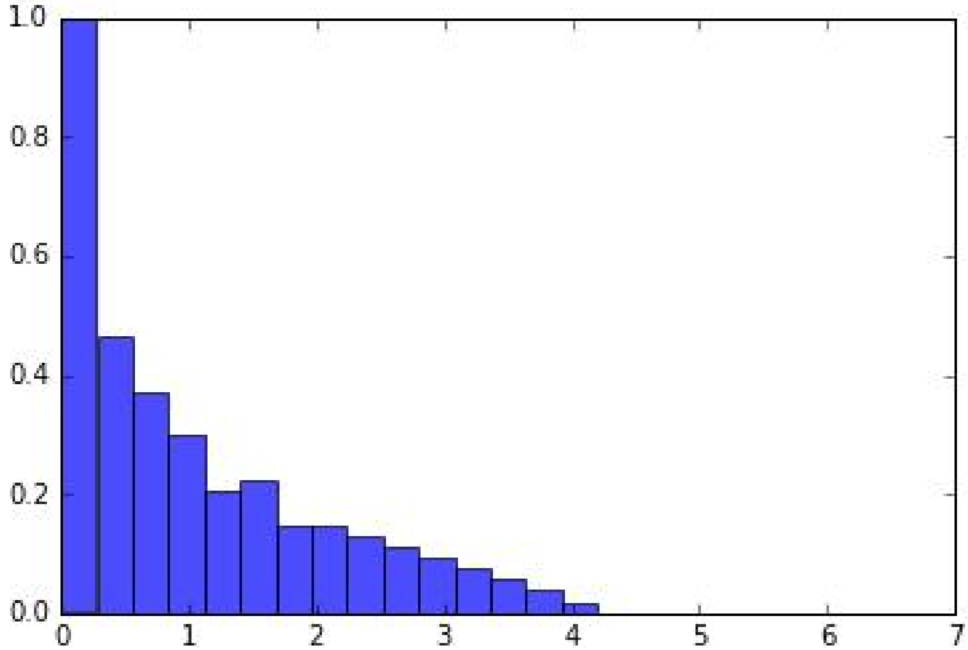

Po przeskalowaniu widzimy, że zgodnie z oczekiwaniami wartości osobliwe dużych prostokątnych macierzy losowych przybierają postać rozkładu Marchenko-Pastur.

G.

Wyniki z kilku pomiarów :

mean t: 191.99160921
standard deviation t: 1.69212032869
Kappa:
mean K:
2261.04404122
std K:
4962.3326014
log(Kappa)
mean logarithm:
6.85604239216
logarithmic average:
949.601470807
>>> runfile('/home/dm/metodynumeryczne/4/IV.py', wdir='/home/dm/metodynumeryczne/4')
mean t: 191.899343097
standard deviation t: 1.35008456548
Kappa:
mean K:
1946.50150317
std K:
3545.32783364
log(Kappa)
mean logarithm:
6.85718717909
logarithmic average:
950.689184633
>>> runfile('/home/dm/metodynumeryczne/4/IV.py', wdir='/home/dm/metodynumeryczne/4')
mean t: 191.926652046
standard deviation t: 1.40654264565
Kappa:
mean K:
2610.58548579
std K:

7151.7701397
log(Kappa)
mean logarithm:
6.8065711523
logarithmic average:
903.766610019
>>> runfile('/home/dm/metodynumeryczne/4/IV.py', wdir='/home/dm/metodynumeryczne/4')
mean t: 192.128003788
standard deviation t: 1.40436826455
Kappa:
mean K:
2221.22474874
std K:
4703.18785279
log(Kappa)
mean logarithm:
6.89017502977
logarithmic average:
982.573381765
>>> runfile('/home/dm/metodynumeryczne/4/IV.py', wdir='/home/dm/metodynumeryczne/4')
mean t: 192.098304731
standard deviation t: 1.46677333943
Kappa:
mean K:
1039.48679441
std K:
1506.0901049
log(Kappa)
mean logarithm:
6.50582850173
logarithmic average:
669.029732092

Zauważalna jest duża standardowa dewiacja średniej arytmetycznej i stosunkowo duże odchyły niej samej. Dla danych o znacznym “rozrzucie” rozsądniejsza okazuje sie średnia logarytmiczna, która daje bardziej powtarzalne rezultaty.

LISTING

```
# -*- coding: utf-8 -*-
"""
Spyder Editor

This is a temporary script file.
"""
#import Gnuplot
import numpy as np
import matplotlib.pyplot as plt
import scipy.stats as ss
import pylab as pl

#A.

n = 192
Matricescount = 100#600 for D. ; 1 for F.


#B.

#print(G)

G = [np.matrix(np.sqrt(1/n) * np.random.randn(n, n)) for i in
range(Matricescount)] # np.sqrt(1/n) * np.mat



#C.

#print(GxGt)

#print(t)
#Z=np.matrix([[1,2,3],[4,5,6],[1,1,1]])
#print(Z)
#print(np.trace(Z))

GxGt = [g * np.transpose(g) for g in G]
t = [np.trace(gxgt) for gxgt in GxGt]
#print(t)
print("mean t:", end= ' ')
```

```
print(np.mean(t))
print("standard deviation t:", end= ' ')
print(np.std(t))



#D.

#print(H)
#print("Eigenvalues:")

#print(EV)
#EV2=[np.linalg.eigvals(h) for h in H]
#print("ev2")
#print(EV2)
#r= cauchy.pdf(0.5)
#plt.hist(r, normed=True, bins='auto',color='r')
#np.histogram
#plt.subplots
#np.linspace
#zet=np.linspace(0,2*np.pi,400)
#plt.hist(zet,bins='auto')
#plt.show


#print("ev done")

#s = s[(s>-3) & (s<3)]   # truncate distribution so it plots well
#plt.plot(s)
#plt.show()
#hist = Gnuplot.Gnuplot()

#Z=np.matrix([[1,2,3],[4,5,6],[1,1,1]])
#print(Z*np.transpose(Z))

H=[((g + np.transpose(g)) / np.sqrt(2)) for g in G]
EV=[np.linalg.eigvalsh(h) for h in H]
plt.hist(EV, normed=True, bins='sqrt')
r = ss.semicircular.rvs(size=100, scale=2)
plt.hist(r, bins='sqrt',normed=True,color='r',alpha=0.4)
plt.show()
```

```
#E.

#plt.hist(cEV, bins=350)
#plt.show()


#print(G)
#print(cEV)
#print(Real)
#print(Imag.ravel())

cEV = [np.linalg.eigvals(g) for g in G]
Real = np.real(cEV)
Imag = np.imag(cEV)
plt.hist2d(Real.ravel(),Imag.ravel(), bins=np.sqrt(n * Matricescount), normed =
True)
plt.show()



#F.



#print(rEV)
#print(revx4)



#print(m_px)
#m_py = m_py[(m_py>0) & (m_py<4)]

W = [gxgt / np.trace(gxgt) for gxgt in GxGt]
rEV = [np.linalg.eigvalsh(w) for w in W]
x=[rev * n for rev in rEV]
plt.hist(x, alpha = 0.7, bins='sqrt', normed = True, range = [0,7])
m_px = np.asarray(x)
m_py = (1/2*np.pi) * np.sqrt((4-m_px)/m_px)
pl.ylim([0,1])
pl.plot(m_px, m_py)



#G.
```

```
SV = [np.linalg.svd(g, compute_uv = False) for g in G]
Sigmamax = [np.amax(sv) for sv in SV]
Sigmamin = [np.amin(sv) for sv in SV]
#print(Sigmamax)
#print(Sigmamin)
K = [np.amax(sv) / np.amin(sv) for sv in SV]
#print(K)
print("Kappa:")
#print(K)
print("mean K:")
print(np.mean(K))
print("std K:")
print(np.std(K))

print("log(Kappa)")
#print(np.log(K))
print("mean logarithm:")
print(np.mean(np.log(K)))
print("logarithmic average:")
print(np.exp(np.mean(np.log(K))))
```